



1. 아래 산점도의 점들에 k-Means 군집화를 적용하려고 한다.



적절한 군집 개수 k 를 정하고, 그렇게 정한 근거를 서술하시오.

2. 아래 산점도에서 새 점(빨간 별, ?)은 두 클래스 무리 사이 경계 부근에 있다.




이 새 점의 분류가 다른 점들보다 불확실한 이유를 쓰고, k 를 너무 작게($k=1$) 잡을 때와 적절히 키울 때의 차이를 서술하시오.

3. 다음은 어떤 암 진단 모델의 혼동행렬이다. (Neg=암 아님, Pos=암. 행=실제, 열=예측)

actual	Actual: Neg	80	12
	Actual: Pos	13	15
		Pred: Neg	Pred: Pos
		predicted	


이 모델을 실제 암 진단에 사용할 때 어떤 문제가 있는지, 혼동행렬의 수치를 근거로 서술하시오.

4. 다음은 메일을 Ham(정상)/Spam(스팸)으로 분류하는 의사결정트리다. (links: 링크 수, caps: 대문자 비율%)



입력 links=8, caps=70 이 트리를 따라 분류되는 과정을 분기별로 순서대로 쓰고, 최종 분류 결과를 서술하시오.


6. 초기 중심점 center1(2,2), center2(5,5)와 7개의 점이 아래와 같이 있다.



(1) 각 점을 더 가까운 중심점에 배정하고, (2) 각 군집에 모인 점들의 평균으로 옮긴 새 중심점 좌표를 두 개 모두 구하시오.


[illegible]

7. 새 점(?)이 두 무리의 정확히 중간(대칭 위치)에 있다.



이 위치에서 $k=1$ 로 분류할 때의 문제와, 이런 애매한 위치에서 k -NN 분류가 갖는 한계를 서술하시오.

8. 점은 세 무리로 보이는데 $k=2$ 로 군집화한 결과다(색이 군집을 나타냄). 아래 두 무리가 같은 색(한 군집)으로 묶였다.




이 결과에서 어떤 일이 일어났는지 설명하고, 적절한 k 가 몇이어야 하는지 쓰시오.

9. k-Means 군집화에서 $k=2$ 로 설정했을 때 알고리즘이 어떻게 동작하는지 단계적으로 서술하시오.

10. 머신러닝으로 문제를 해결하는 전체 과정을, 데이터를 준비하는 단계부터 모델 성능을 확인하는 단계까지 순서대로 서술하시오.


12. 실제 정상(Neg)이 990개, 양성(Pos)이 10개인 매우 불균형한 데이터의 혼동행렬이다.



이 모델의 정확도를 구하고, 정확도만으로 이 모델을 좋다고 할 수 없는 이유를 서술하시오.

11. 로지스틱회귀는 이름에 '회귀'가 들어가 있어 회귀(숫자 예측)로 오해하기 쉽지만, 실제로는 분류 알고리즘이다. 로지스틱회귀가 회귀가 아니라 분류인 이유를 서술하시오.

13. 아래 그림에서 새 점(?)으로부터 가장 가까운 이웃 4개가 class A 2개, class B 2개로 같은 거리에 있다.



k=4로 분류하면 어떤 문제가 생기는지, 그리고 이 문제를 어떻게 해결할 수 있는지 서술하시오.


15. 두 모델 X, Y의 혼동행렬이다. (Pos=질병 있음. 행=실제, 열=예측)

		Model X		Model Y	
actual	Actual: Neg	60	30	88	2
	Actual: Pos	2	28	18	12
		predicted		predicted	
		Pred: Neg	Pred: Pos	Pred: Neg	Pred: Pos

암 진단처럼 실제 환자(Pos)를 놓치면 안 되는 상황에서 어느 모델이 더 적합한지, 위음성(실제 양성을 음성으로 판정)을 근거로 서술하시오.


14. k-최근접 이웃(k-NN) 분류에서 k=2로 설정했을 때 분류가 어떻게 이루어지는지, 그리고 어떤 문제가 생길 수 있는지 서술하시오.

18. 다음 의사결정트리는 맨 위(루트)에서 study_hours로 먼저 나눈다.




study_hours가 다른 특성보다 중요하게 쓰였다고 볼 수 있는 이유를 서술하시오.

19. 루트 노드는 No 5, Yes 5로 두 클래스가 반반 섞여 있다. color 기준으로 한 번 나누자 두 잎이 각각 한 클래스만 남아 순수해졌다.




의사결정트리가 어떤 기준으로 노드를 나누는지 이 그림을 예로 들어 서술하시오.

20. 어떤 데이터에 선형회귀(빨간 직선)를 적용했더니 결정계수 R^2 가 0.05로 매우 낮게 나왔다.



데이터의 분포 모양에 주목하여, R^2 가 이렇게 낮은 이유를 서술하시오.


22. 사람 눈에는 위/아래 두 줄(띠)로 보이는, 가로로 길게 늘어선 데이터다.



이 데이터에 k-Means($k=2$)를 적용하면 위/아래 두 줄로 잘 나누지 못할 수 있다. 그 이유를 서술하시오.

21. R^2 (결정계수)는 회귀 모델의 성능을 나타내는 지표다. R^2 가 무엇을 의미하는지, 그리고 값이 1에 가까울 때와 0에 가까울 때가 각각 어떤 상태인지 서술하시오.


23. 아래 산점도의 데이터(class A, B)를 학습에 사용한다. 다음 코드를 읽고 물음에 답하시오.



```
1 from sklearn.neighbors import KNeighborsClassifier
2
3 model = KNeighborsClassifier(n_neighbors=
4                             )
5 model.fit(X, y)           # X: 점들의 좌표,
6                             y: 각 점의 클래스(A 또는 B)
7 print(model.predict([4.5, 4.5])) # 새 점 [4.5, 4.5] 분류
```


- (1) 이 코드가 사용하는 분류 알고리즘의 이름을 쓰시오.
- (2) 빈칸(n_neighbors)에 들어갈 k값을 정하고, 그렇게 정한 이유를 서술하시오.

24. 같은 종류의 데이터에 각각 선형회귀를 적용한 두 그래프 A, B다.




두 그래프 중 결정계수 R^2 가 더 높은 쪽을 고르고, 그렇게 판단한 근거를 서술하시오.

25. 왼쪽은 색(정답)이 없는 데이터, 오른쪽은 색(정답)이 있는 데이터다.




k-Means는 둘 중 어느 상황의 학습에 해당하며, 그렇게 판단하는 이유를 서술하시오.

26. 학습 데이터는 $x=1\sim 10$ 범위인데, 회귀직선을 그대로 연장해 $x=20$ 일 때의 값을 예측했다(빨간 별).




이 $x=20$ 에 대한 예측을 그대로 믿기 어려운 이유를 서술하시오.

27. class A가 16개, class B가 5개인 불균형 데이터다. 새 점(?)은 B 무리에 가깝다.




k를 아주 크게(예: $k=15$) 잡으면 새 점이 어떤 클래스로 분류될지 예상하고, 그 이유를 서술하시오.

28. 두 그래프 A, B의 회귀직선은 기울기의 부호가 서로 다르다.



각 그래프에서 x와 y가 어떤 관계인지 기울기 부호를 근거로 서술하시오.

29. 아래 그래프에서 회색 수직선은 각 점과 회귀직선 사이의 세로 거리(잔차)를 나타낸다.



선형회귀가 직선의 기울기와 절편을 정할 때 이 잔차들을 어떻게 사용하는지 서술하시오.


30. 다음은 데이터를 학습에 쓰기 전에 정리하는 코드이다.

```
1 import pandas as pd
2
3 df = pd.read_csv('students.csv')
4 df['math'] = df['math'].fillna(df['math'].mean())
5 df = df.dropna()
6 df = df[df['score'] <= 100]
```

2~4번째 줄은 각각 어떤 처리를 하며, 왜 그 처리가 필요한지 서술하시오.

32. 두 클래스가 무리를 이룬 산점도에 새 점(빨간 별, ?)을 분류하려고 한다. (전체 데이터는 class A 12개 + class B 8개 = 20개)


- ㉠. 선형회귀
- ㉡. 로지스틱회귀
- ㉢. k-NN(최근접 이웃)
- ㉣. 의사결정트리
- ㉤. k-Means



값은 $k=2$, $k=100$ 으로 설정했다. 각 설정에서 새 점(?) 이 어떤 클래스로 분류될지 예상하고, 둘 중 더 잘못된 설정이 무엇인지 이유와 함께 서술하시오.

[illegible]

33. 같은 데이터에 k-Means를 적용하는데, 초기 중심점(빨간 X) 위치만 다르게 두 번 실행했다(start A, start B).



두 실행의 최종 결과가 달라질 수 있는 이유와, 결과를 매번 똑같이 만드는 방법을 서술하시오.


35. 다음은 스팸 필터의 혼동행렬이다. (Ham=정상 메일, Spam=스팸. 행=실제, 열=예측)

actual	Actual: Ham	35	15
	Actual: Spam	3	47
		Pred: Ham	Pred: Spam
		predicted	

이 필터를 사용할 때 사용자가 겪는 가장 곤란한 문제가 무엇인지, 혼동행렬의 수치를 근거로 서술하시오.


34. k-NN과 k-Means는 둘 다 이름에 'k'가 있지만 서로 다른 알고리즘이다. 두 알고리즘이 (지도/비지도), (하는 일), (k의 의미) 측면에서 어떻게 다른지 서술하시오.

36. 같은 종류의 데이터에 각각 선형회귀(빨간 직선)를 적용한 두 그래프 A, B다. (R^2 는 결정계수)



A와 B 중 예측 성능이 더 좋은 쪽을 고르고, 그렇게 판단한 근거와 성능이 낮은 쪽이 왜 낮은지 서술하시오.

37. 두 특성 annual_income(0~1000)과 rating(0~10)으로 k-NN 분류를 하려고 한다. 아래 산점도와 코드를 보시오.




```
1 from sklearn.neighbors import KNeighborsClassifier
2 model = KNeighborsClassifier(n_neighbors=3)
3 model.fit(X, y) # X의 두 특성: annual_income(0~1000), rating(0~10)
4 print(model.predict(500, 5.2))
```

두 특성의 값 범위가 크게 다른 상태로 k-NN을 적용하면 어떤 문제가 생기는지와 그 해결 방법을 서술하시오.

38. 지도학습 모델을 만들 때 보통 데이터를 train(학습용)과 test(평가용)로 나눈다. 데이터를 이렇게 나누는 이유를 서술하시오.


40. 아래 산점도에서 class A 무리 쪽에 class B 점 하나가 섞여 있다(노이즈/이상치). 새 점(빨간 별, ?)을 분류하려고 한다.



새 점(?)을 $k=1$ 과 $k=3$ 으로 분류하면 각각 어떤 클래스가 되는지 예상하고, $k=1$ 을 쓸 때의 위험을 서술하시오.


39. k-최근접 이웃(k-NN) 분류에서 k값을 보통 홀수로 정하는 이유를 서술하시오. (클래스는 2개라고 가정한다.)

41. 어떤 데이터에 선형회귀를 적용했더니 회귀직선(빨간 선)이 대부분의 점들과 동떨어지게 나왔다.




이 직선이 데이터의 경향과 맞지 않는 원인이 무엇인지, 그리고 어떻게 해결해야 하는지 서술하시오.

42. 세 클래스(A, B, C)의 데이터가 있고 새 점(?)을 분류하려고 한다.



k=3으로 분류할 때 클래스를 정하는 방법을 설명하고, 그림을 근거로 새 점이 어느 클래스로 분류될지 쓰시오.

43. 같은 데이터로 만든 두 의사결정트리다. Tree P는 얇고, Tree Q는 매우 깊어 앞마다 학습 데이터가 1개씩 남았다.



학습 데이터에 과적합된 트리는 무엇인지 고르고, 그렇게 판단한 이유와 과적합의 문제점, 막는 방법을 서술하시오.

[illegible]

1. 정답: $k=3$ 이 적절하다. 점들이 세 무리로 뚜렷하게 뭉쳐 있으므로 군집 개수를 데이터가 자연스럽게 나뉘는 무리의 수인 3에 맞추는 것이 좋다.

채점 포인트

점들이 3개 무리로 뚜렷이 뭉쳐 있음.

k 는 데이터가 자연스럽게 나뉘는 무리 수에 맞춤 $\rightarrow k=3$.

ml-knn-n01

2. 정답: 새 점이 두 무리의 경계 부근에 있어, 가까운 이웃에 두 클래스가 섞여 있을 수 있어 어느 쪽으로도 단정하기 어렵다. $k=1$ 은 가장 가까운 한 점에만 의존해 그 점의 클래스에 따라 결과가 쉽게 흔들린다(불안정). k 를 적당히 키우면 주변 여러 점의 다수결로 결정하므로 더 안정적으로 분류된다.

채점 포인트

경계 부근이라 가까운 이웃에 두 클래스가 섞여 분류가 모호하다.

$k=1$: 가장 가까운 한 점에 좌우됨 $\rightarrow$ 불안정/노이즈에 민감.

k 를 키우면 주변 다수결로 더 안정적으로 분류.

3. 정답: 실제 암 환자(Pos) 28명 중 13명을 음성(Neg)으로 잘못 판정했다(위음성). 암 진단에서 위음성은 암 환자를 놓쳐 치료 시기를 놓치게 하는 치명적 오류다. 전체 정확도는 $(80+15)/120 \approx 79\%$ 로 나쁘지 않아 보이지만, 정작 암 환자의 약 46%(13/28)를 놓치므로 진단 모델로는 위험하다. 위음성을 줄이는 방향으로 개선해야 한다.

채점 포인트

혼동행렬 읽기: 실제 Pos(암) = 13(위음성) + 15(맞춤) = 28명.

위음성(FN)=13: 실제 암인데 음성으로 판정 $\rightarrow$ 환자를 놓침.

암 진단에서는 위음성이 위양성보다 훨씬 위험하다(치료 시기 놓침).

정확도(약 79%)만 보면 괜찮아 보여도 암 환자를 절반 가까이 놓침 $\rightarrow$ 부적합.

핵심: '위음성이 많아 암 환자를 놓친다'가 들어가면 정답.

ml-dt-n01

4. 정답: 루트에서 $\text{links} \leq 5$? $8 \leq 5$ 는 거짓이므로 False(오른쪽)로 간다. 다음 노드 $\text{caps} \leq 40$? $70 \leq 40$ 은 거짓이므로 False(오른쪽)로 간다. 도달한 잎은 Ham 0, Spam 5이므로 더 많은 쪽인 Spam으로 분류된다.

채점 포인트

$\text{links} \leq 5$? 8은 거짓 $\rightarrow$ 오른쪽(False).

$\text{caps} \leq 40$? 70은 거짓 $\rightarrow$ 오른쪽(False).

도달한 잎 Ham 0, Spam 5 $\rightarrow$ Spam으로 분류.

5. 정답: 정확도 = 맞게 분류한 수 / 전체 수. 맞게 분류한 것은 대각선의 50(실제 Neg를 Neg로) + 40(실제 Pos를 Pos로) = 90이고, 전체는 50+10+20+40 = 120이다. 따라서 정확도 = $90/120 = 0.75 = 75\%$ 이다.

채점 포인트

맞게 분류 = 대각선 합 = $50 + 40 = 90$.

전체 = $50+10+20+40 = 120$.

정확도 = $90/120 = 75\%$.

7. 정답: 정중앙이라 두 무리까지의 거리가 거의 같아서, 가장 가까운 한 점($k=1$)이 어느 무리의 점이나에 따라 결과가 쉽게 뒤바뀐다(불안정). 이렇게 경계의 애매한 위치에서는 k 를 키워도 양쪽 무리가 비슷하게 이웃에 포함되어 어느 쪽이라고 확신하기 어렵다. 즉 k -NN은 경계 부근의 점을 안정적으로 분류하기 어렵다.

채점 포인트

두 무리까지 거리가 비슷 -> $k=1$ 은 한 점에 좌우되어 불안정.

k 를 키워도 양쪽이 비슷하게 포함되어 확신 낮음.

경계 부근 점은 k -NN으로 안정적 분류가 어렵다.

6. 정답: (1) 배정: `center1 <- (1,1), (1,2), (2,1)` / `center2 <- (6,6), (7,6), (6,7), (7,7)`. (2) 새 중심: `center1 = ((1+1+2)/3, (1+2+1)/3) = (약 1.33, 약 1.33)`. `center2 = ((6+7+6+7)/4, (6+6+7+7)/4) = (6.5, 6.5)`.

채점 포인트

각 점을 더 가까운 중심에 배정: 좌하 3개 -> center1, 우상 4개 -> center2.

center1 평균 = $(4/3, 4/3) = \text{약 } (1.33, 1.33)$.

center2 평균 = $(26/4, 26/4) = (6.5, 6.5)$.

8. 정답: 군집을 2개만 만들도록 했기 때문에, 서로 가까운 아래 두 무리가 하나의 군집으로 강제로 합쳐졌다. 실제 무리는 3개이므로 $k=3$ 으로 해야 세 무리가 각각 제대로 나뉜다.

채점 포인트

$k=2$ 라 가까운 두 무리가 한 군집으로 강제 병합됨.

무리가 3개 -> 적절한 $k=3$.

9. 정답: 1) 중심점 2개를 무작위 위치에 정한다(초기화).
 2) 각 점을 더 가까운 중심점에 배정해 2개 그룹을 만든다.
 3) 각 그룹에 속한 점들의 평균 위치로 중심점을 옮긴다(재설정). 4) 배정과 이동을 더 이상 변화가 없을 때까지 반복하고 멈춘다. 결과로 데이터가 2개 군집으로 나뉜다.

채점 포인트

초기화: 중심점(centroid)을 $k=2$ 개, 보통 무작위 위치에 둔다.

배정: 각 점을 더 가까운 중심점 쪽으로 보내 2개 그룹을 만든다.

재설정: 각 그룹 점들의 평균으로 중심점을 이동한다.

반복/종료: 배정->이동을 변화가 없을 때까지 반복한다.

4단계(초기화/배정/재설정/반복종료)가 들어가면 정답.

10. 정답: 1) 데이터 로드: csv 등에서 데이터를 불러온다.
 2) 전처리: 결측치·이상치를 정리하는 등 데이터를 학습에 맞게 다듬는다. 3) 데이터 분리: train(학습용)과 test(평가용)로 나눈다. 4) 학습(fit): train 데이터로 모델을 학습시킨다. 5) 예측/평가: test 데이터로 예측하고 R2(회귀)·정확도(분류) 등으로 성능을 평가한다.

채점 포인트

데이터 로드 -> 전처리 -> (train/test 분리) -> 학습(fit) -> 예측/평가 순서.

전처리(결측치·이상치 정리)와 학습/평가 단계가 들어가야 함.

순서가 맞고 각 단계가 무엇을 하는지 설명되면 정답.

11. 정답: 로지스틱회귀는 연속적인 숫자를 예측하는 것이 아니라, 데이터가 어느 범주(예: 합격/불합격, 양성/음성)에 속하는지를 구분한다. 로지스틱 함수로 0~1 사이 값(확률)을 구한 뒤 기준(보통 0.5)으로 범주를 나누므로 결과가 범주다. 따라서 이름과 달리 분류 알고리즘이다.

채점 포인트

회귀=숫자 예측, 분류=범주 예측.

로지스틱회귀의 결과는 숫자가 아니라 범주(예: 0/1, 합격/불합격).

로지스틱 함수로 확률(0~1)을 구하고 기준으로 나눠 범주를 정함 -> 분류.

'이름은 회귀지만 출력이 범주라 분류'가 핵심.

12. 정답: 정확도 = $(985+2)/1000 = \text{약 } 98.7\%$ 로 높아 보인다. 하지만 실제 양성 10개 중 2개만 맞히고 8개를 놓쳤다. 데이터가 정상 쪽으로 크게 치우쳐 있어 모두 정상이라고만 찍어도 정확도가 높게 나오므로, 정작 찾아야 할 양성을 잘 찾는지는 정확도만으로 알 수 없다.

채점 포인트

정확도 = $(985+2)/1000 = \text{약 } 98.7\%$.

그러나 양성 10개 중 2개만 맞힘(8개 놓침).

불균형 데이터에서는 정확도가 높아도 소수 클래스를 못 찾을 수 있음.

14. 정답: 가장 가까운 2개의 다수결로 분류하지만, 두 이웃의 클래스가 다르면 1:1 동점이 되어 분류를 정할 수 없다(짝수 k의 동점 문제). 그래서 k는 보통 홀수로 둔다.

채점 포인트

새 데이터에서 가장 가까운 이웃 2개를 찾는다.

그 2개의 클래스를 다수결(투표)한다.

두 이웃의 클래스가 서로 다르면 1:1 동점 -> 다수결로 결정 불가.

결론: 짝수 k(특히 2)는 동점이 생길 수 있어, k는 홀수가 바람직하다.

13. 정답: 가장 가까운 4개가 A 2개, B 2개로 2:2 동점이거나 다수결로 클래스를 정할 수 없다. k를 홀수(예: 3 또는 5)로 바꾸면 두 클래스의 표 합이 홀수가 되어 갈아질 수 없으므로 동점이 사라지고 분류가 결정된다.

채점 포인트

A 2 : B 2 동점 -> 다수결 불가.

짝수 k(특히 클래스 2개)에서 동점이 생길 수 있음.

해결: k를 홀수로 설정.

15. 정답: Model X가 더 적합하다. 환자를 놓치면 안 되는 상황에서 치명적인 오류는 실제 양성을 음성으로 판정하는 위음성이다. 위음성은 Model X가 2명, Model Y가 18명으로, X가 환자를 훨씬 적게 놓친다. X는 대신 정상인을 양성으로 판정하는 위양성이 많지만(30명), 이 상황에서는 환자를 놓치지 않는 것이 우선이므로 X가 낫다.

채점 포인트

환자 놓침 = 위음성(실제 Pos를 Neg로). X=2, Y=18.

X가 위음성이 훨씬 적어 환자를 덜 놓침.

환자를 놓치면 안 되는 상황 -> Model X가 적합.

16. 정답: 공부 시간(X)으로 시험 점수(y)를, 특히 7시간 공부했을 때의 예상 점수를 예측한다. 예측 결과는 숫자(회귀)다. 시험 점수처럼 연속적인 수치를 예측하므로 회귀이며, 범주(합격/불합격 등)를 고르는 분류와 다르다.

채점 포인트

fit(X, y)로 공부시간-점수 관계를 학습하고 predict(7)로 7시간일 때 점수를 예측.

점수는 연속적인 숫자 -> 회귀(LinearRegression).

범주를 고르는 분류와 구분되면 정답.

18. 정답: 루트(맨 위)에서 나누는 특성은 데이터를 클래스별로 가장 잘 갈라주는(불순도를 가장 크게 줄이는) 특성이다. study_hours <= 4로 나누자 한쪽이 거의 Fail로 몰려 분류가 크게 좋아지므로, 이 트리에서 study_hours가 가장 중요한 특성이라고 볼 수 있다.

채점 포인트

루트 특성 = 데이터를 가장 잘 갈라주는(불순도 최대 감소) 특성.

study_hours로 나누자 한쪽이 거의 Fail -> 분류가 크게 개선.

따라서 study_hours가 가장 중요한 특성.

17. 정답: (1) 비지도학습 (정답 y 없이 X만 사용하고 fit_predict로 군집을 찾음). (2) k=3 (점들이 세 무리로 뚜렷이 뭉쳐 있으므로). (3) 전체 데이터가 24개뿐이라 군집을 100개 만들 수 없다. 점이 하나도 없는 빈 군집이 생겨 에러가 나거나, 사실상 점마다 따로 나뉘어 군집화가 무의미해진다.

채점 포인트

(1) X(좌표)만 있고 정답 y가 없으며 fit_predict로 묶음 -> 비지도학습.

(2) 산점도에 점 무리가 3개 -> k=3.

(3) 전체 점이 24개인데 k=100이면 데이터 수보다 군집이 많다.

-> 빈 군집 발생(에러) / 군집화가 의미를 잃음.

19. 정답: 의사결정트리는 한 노드에 여러 클래스가 섞인 정도(불순도)가 가장 많이 줄어드는(가장 순수하게 갈라지는) 특성과 기준값을 골라 나눈다. 이 그림에서는 color 기준으로 나누자 한쪽은 No만, 다른 쪽은 Yes만 남아 양쪽이 완전히 순수해졌으므로, color가 데이터를 가장 잘 갈라주는 좋은 분할 기준이다.

채점 포인트

섞인 정도(불순도)가 가장 많이 줄어드는 기준으로 분할.

color 분할 후 양쪽이 한 클래스만 남아 순수해짐.

순수하게 갈라줄수록 좋은 분할.

20. 정답: 데이터가 직선이 아니라 곡선(비선형) 모양으로 분포해 있어서, 어떤 직선을 그어도 점들의 경향을 따라갈 수 없다. 선형회귀는 직선만 그릴 수 있어 곡선 관계를 표현하지 못하므로 R2가 낮다. 이런 경우 곡선을 표현할 수 있는 모델이 필요하다.

채점 포인트

데이터가 비선형(곡선) 관계.

직선 모델은 곡선을 못 따라감 -> R2 낮음.

(분산이 아니라 '비선형'이 핵심 원인)

22. 정답: k-Means는 중심점까지의 거리로 점을 묶어 둥근(구형) 모양의 군집을 가정한다. 가로로 긴 띠에서는 같은 줄 안에서도 좌우 끝이 서로 멀고, 위아래 줄이 오히려 가까운 구간이 있다. 그래서 거리 기준으로는 위/아래가 아니라 좌/우로 잘리는 식으로 엉뚱하게 나뉠 수 있다.

채점 포인트

k-Means는 중심 거리 기반이라 둥근 군집을 가정.

긴 띠는 같은 줄 좌우가 멀고 위아래가 가까워 좌/우로 잘릴 수 있음.

모양이 길쭉하거나 겹친 분포에서 k-Means의 한계.

21. 정답: R2(결정계수)는 회귀 모델이 데이터의 경향을 얼마나 잘 설명(예측)하는지를 보통 0~1 사이로 나타낸 값이다. 1에 가까울수록 점들이 회귀직선에 가깝게 모여 예측이 잘 맞고, 0에 가까울수록 직선이 데이터를 잘 설명하지 못해 예측이 부정확하다.

채점 포인트

R2는 회귀의 예측 성능(직선이 데이터를 얼마나 설명하는지)을 나타낸다.

보통 0~1 범위, 1에 가까울수록 좋음(직선에 잘 맞춤).

0에 가까우면 직선이 데이터를 설명하지 못함(성능 나쁨).

23. 정답: (1) k-NN(k-최근접 이웃). (2) 예: k=3 또는 5. 짝수는 동점이 생기므로 홀수가 좋고, k=1은 이상치/노이즈에 민감, k가 너무 크면 멀리 있는 점까지 포함되어 클래스 경계가 흐려진다. 데이터가 두 무리로 비교적 잘 나뉘므로 작은 홀수면 충분하다.

채점 포인트

(1) KNeighborsClassifier는 k-NN(k-최근접 이웃) 분류기다.

(2) 핵심 근거 3가지가 들어가면 정답 인정:

- 홀수 권장(짝수는 동점).

- k=1처럼 너무 작으면 노이즈/이상치 하나에 휘둘림.

- k가 너무 크면 먼 점까지 포함 -> 경계가 흐려지고 다수 클래스로 쏠림.

구체적 k 숫자(예: 3, 5)는 위 이유와 함께면 정답.

24. 정답: graph A의 R2가 더 높다. A는 점들이 직선에 바짝 붙어 있어(흩어짐이 작아) 직선이 데이터를 잘 설명하므로 R2가 1에 가깝다. B는 점들이 직선에서 넓게 흩어져 있어 직선의 설명력이 떨어져 R2가 낮다.

채점 포인트

R2는 1에 가까울수록 점들이 직선에 잘 맞음.

A: 직선에 바짝 붙음(분산 작음) -> R2 높음.

B: 넓게 흩어짐 -> R2 낮음.

26. 정답: 모델은 학습한 범위($x=1\sim10$) 안에서의 관계만 확인한 것이다. $x=20$ 은 한 번도 학습하지 않은 범위 밖(외삽)이라, 그 구간에서도 똑같은 직선 관계가 이어진다는 보장이 없다. 실제로는 관계가 달라질 수 있어 예측이 크게 빗나갈 수 있다.

채점 포인트

$x=20$ 은 학습 범위($1\sim10$) 밖 -> 외삽.

범위 밖에서도 같은 직선 관계가 유지된다는 보장 없음.

예측 신뢰도 낮음.

25. 정답: 왼쪽처럼 정답(레이블)이 없는 데이터를 다루는 비지도학습이다. k-Means는 정답을 주지 않고 데이터의 분포(점들이 가까운 정도)만 보고 비슷한 것끼리 묶어 군집을 찾기 때문이다.

채점 포인트

k-Means는 정답(y) 없이 데이터만으로 묶음 -> 비지도 학습(왼쪽).

분포만 보고 비슷한 것끼리 군집화.

27. 정답: A로 분류될 가능성이 크다. k를 크게 잡으면 멀리 있는 점까지 이웃에 포함되는데, 전체에 A가 훨씬 많아 (16 대 5) 다수결이 A로 쏠리기 때문이다. 그래서 새 점이 실제로는 B 무리에 가까운데도 A로 잘못 분류될 수 있다. 데이터가 불균형할 때 너무 큰 k는 다수 클래스로 쏠리는 위험이 있다.

채점 포인트

큰 k -> 멀리 있는 점까지 이웃에 포함.

전체에 A가 많아 다수결이 A로 쏠림 -> B 근처인데도 A로 오분류.

불균형 데이터에서 과도하게 큰 k의 위험.

28. 정답: graph A는 직선 기울기가 양수라 x가 커질수록 y도 커지는 양의 상관(비례) 관계다. graph B는 기울기가 음수라 x가 커질수록 y는 작아지는 음의 상관(반비례) 관계다.

채점 포인트

A: 기울기 양수 -> x 증가 시 y 증가(양의 상관).

B: 기울기 음수 -> x 증가 시 y 감소(음의 상관).

29. 정답: 선형회귀는 각 점과 직선 사이의 세로 거리(잔차)들을 제공해서 모두 더한 값이 가장 작아지도록 직선의 기울기와 절편을 정한다. 즉 전체 오차(잔차)가 최소가 되는 직선을 찾는 것이다.

채점 포인트

잔차 = 점과 직선 사이의 세로 거리(오차).

잔차를 제공해 더한 값(전체 오차)이 최소가 되도록 직선 결정.

30. 정답: `fillna(df['math'].mean())`: math 열의 빈 값(결측치)을 그 열의 평균으로 채운다 - 빈 값이 있으면 학습이 안 되므로. `dropna()`: 아직 남아 있는 결측치가 있는 행을 제거한다 - 불완전한 데이터를 빼기 위해. `df[df['score'] <= 100]`: 점수가 100을 넘는 비정상 값(이상치)을 걸러낸다 - 잘못된 데이터가 결과를 왜곡하지 않도록. 즉 결측치와 이상치를 정리해 모델이 올바른 데이터로 학습하게 한다.

채점 포인트

2줄 `fillna(mean)`: 결측치를 평균으로 대체.

3줄 `dropna`: 남은 결측치 행 제거.

4줄 조건 필터: `score>100` 같은 이상치 제거.

공통 이유: 결측치/이상치가 있으면 학습이 안 되거나 결과가 왜곡됨.

31. 정답: 선형회귀: 지도학습·회귀 / 로지스틱회귀: 지도학습·분류 / k-NN: 지도학습·분류 / 의사결정트리: 지도학습·분류 / k-Means: 비지도학습·군집

채점 포인트

지도/비지도: 정답(레이블)을 쓰면 지도, 안 쓰면 비지도.

회귀=숫자 예측, 분류=범주 예측, 군집=정답 없이 그룹화.

ㄱ 선형회귀: 지도·회귀. ㄴ 로지스틱회귀: 지도·분류(이름은 회귀지만 분류).

ㄷ k-NN: 지도·분류. ㄹ 의사결정트리: 지도·분류. ㅁ k-Means: 비지도·군집.

32. 정답: $k=2$: 가장 가까운 2개가 모두 class B이므로 B로 분류된다(동작은 정상이지만, 짝수 k 는 동점이 생길 수 있어 일반적으로 권장되지 않는다). $k=100$: 전체 데이터가 20개뿐이라 이웃을 100개 볼 수 없고, 설령 전체를 본다고 해도 다수 클래스 A로만 분류되어 새 점의 위치(B에 가까움)가 무시된다. 따라서 둘 중 더 잘못된 설정은 $k=100$ 이다.

채점 포인트

새 점은 class B 무리에 확실히 가깝다.

$k=2$: 가장 가까운 2개가 모두 B -> B로 분류(위치는 반영). 다만 짝수 k 라 동점 위험이 있어 이상적이진 않다.

$k=100$: 전체가 20개라 이웃 100개는 불가능(데이터 수 초과).

설령 전체를 이웃으로 보면 다수인 A로만 분류 -> 새 점 위치가 전혀 반영 안 됨.

결론: $k=2$ 는 사소한 결함(짝수)일 뿐이지만 $k=100$ 은 위치 정보를 통째로 잃는 근본적 오류 -> 더 잘못된 것은 $k=100$.

34. 정답: k -NN은 지도학습 분류 알고리즘으로, 정답이 있는 데이터를 이용해 새 데이터를 가장 가까운 이웃들의 다수결로 분류한다. 여기서 k 는 '참고할 이웃의 수'다. k -Means는 비지도학습 군집 알고리즘으로, 정답 없이 비슷한 데이터끼리 묶는다. 여기서 k 는 '나눌 군집(중심점)의 개수'다.

채점 포인트

지도/비지도: k -NN은 지도(정답 사용), k -Means는 비지도(정답 없음).

하는 일: k -NN은 분류, k -Means는 군집.

k 의 의미: k -NN은 이웃 수, k -Means는 군집 수.

세 측면이 모두 들어가면 정답.

35. 정답: 정상 메일(Ham) 50개 중 15개를 스팸으로 잘못 분류했다(위양성). 스팸 필터에서 위양성은 중요한 정상 메일이 스팸함으로 가서 사용자가 놓치게 되는 문제라 특히 곤란하다. 스팸을 일부 못 거르는 것(위음성, 3개)보다, 정상 메일을 스팸으로 버리는 위양성을 줄이는 것이 더 중요하다.

채점 포인트

정상 메일 50개 중 15개를 스팸으로 오분류(위양성).

위양성 -> 중요한 정상 메일을 놓침(가장 곤란).

스팸 필터에서는 위양성을 줄이는 것이 중요.

33. 정답: k -Means는 처음 중심점을 보통 무작위로 정하는데, 시작 위치가 다르면 점들이 서로 다른 군집으로 배정되어 반복 결과(최종 군집)가 달라질 수 있다. `random_state`(시드)를 지정하면 초기 중심이 항상 같은 위치로 정해져 결과를 똑같이 재현할 수 있다.

채점 포인트

초기 중심이 무작위라 시작 위치에 따라 결과가 달라질 수 있음(초기화 의존).

해결: `random_state`(시드) 고정 -> 초기 중심 고정 -> 재현 가능.

36. 정답: B($R^2=0.94$)가 A($R^2=0.34$)보다 성능이 좋다. R^2 가 1에 가까울수록 점들이 직선에 가깝게 모여 예측이 잘 맞기 때문이다. A는 점들이 직선에서 멀리 넓게 흩어져 있어(분산이 큼) 직선으로 예측하기 어려워 R^2 가 낮다.

채점 포인트

R^2 (결정계수)는 1에 가까울수록 데이터가 직선에 잘 맞는다는 뜻.

B의 $R^2(0.94)$ 가 A의 $R^2(0.34)$ 보다 크므로 B가 성능이 좋다.

A가 낮은 이유: 점들이 직선에서 멀리 흩어져 있어(큰 분산) 직선이 잘 설명하지 못한다.

(이상치/비선형 관계도 R^2 를 낮추는 원인으로 언급하면 가점)

38. 정답: 학습에 사용하지 않은 새 데이터(test)로 평가해야, 모델이 처음 보는 데이터에도 잘 작동하는지(일반화) 확인할 수 있다. 학습에 쓴 데이터로만 평가하면 모델이 그 데이터를 외운 것일 수 있어 실제 성능을 제대로 알 수 없다.

채점 포인트

test는 학습에 안 쓴 데이터 -> 새 데이터에 대한 성능(일반화) 측정.

train으로만 평가하면 외워서 잘 맞는 것과 구분이 안 됨.

'일반화 확인'(또는 새 데이터 성능)이 들어가면 정답.

37. 정답: k-NN은 거리로 이웃을 찾는데, 값의 범위가 큰 `annual_income(0~1000)`이 거리를 거의 결정해버려 범위가 작은 `rating(0~10)`은 사실상 무시된다. 두 특성을 같은 기준으로 맞추는 표준화(스케일링, 예: `StandardScaler`)를 적용해 각 특성이 거리에 공평하게 반영되도록 해야 한다.

채점 포인트

거리 계산에서 범위가 큰 특성(income)이 지배 -> 작은 특성(rating)이 무시됨.

해결: 표준화/정규화(스케일링)로 두 특성 범위를 맞춤.

스케일링 후 각 특성이 거리에 공평하게 기여.

39. 정답: k가 짝수이면 두 클래스의 이웃 수가 같아지는 동점(예: 2:2, 3:3)이 생길 수 있어 어느 쪽으로 분류할지 정할 수 없다. k를 홀수로 하면 두 클래스의 표 합이 홀수라 같아질 수 없으므로 항상 한쪽이 다수가 되어 분류가 결정된다.

채점 포인트

이웃들의 클래스를 다수결로 분류한다.

클래스가 2개일 때 k가 짝수면 표가 반반(예: 2:2)이 되는 동점이 가능하다.

동점이면 다수결로 클래스를 정할 수 없다.

k가 홀수면 두 클래스의 표 합이 홀수라 같아질 수 없으므로 항상 다수가 정해진다.

40. 정답: $k=1$: 가장 가까운 1개가 A 무리에 섞인 B 이상치이므로 B로 분류된다(오분류). $k=3$: 가까운 3개는 B 이상치 1개 + 주변 A 2개라 A로 분류된다(정상). $k=1$ 은 가장 가까운 한 점만 보기 때문에 그 점이 노이즈/이상치면 그대로 오분류된다(이상치에 매우 민감, 과적합). k 를 키우면 주변 다수로 보정된다.

채점 포인트

새 점은 실제로는 A 무리 영역에 있다.

$k=1$: 가장 가까운 한 점이 하필 섞여 있던 B 이상치 -> B로 오분류.

$k=3$: 가까운 3개 = B 이상치 1 + A 2 -> 다수결로 A(정상 분류).

결론: $k=1$ 은 가장 가까운 한 점에만 의존해 노이즈/이상치 하나에 휘둘린다(과적합).

k 를 적당히 키우면 주변 여러 점의 다수결로 이상치 영향을 줄일 수 있다.

42. 정답: 새 점에서 가장 가까운 이웃 3개를 찾아 그 클래스를 다수결로 정한다. 새 점은 class B 무리에 가장 가까우므로 가까운 3개가 대부분 B여서 B로 분류된다. 클래스가 3개여도 다수결 방식은 동일하다.

채점 포인트

가장 가까운 $k(=3)$ 개 이웃의 다수결로 결정.

새 점은 B 무리에 가장 가까움 -> B로 분류.

클래스가 여러 개여도 다수결 원리는 같다.

43. 정답: Tree Q가 과적합되었다. 앞마다 학습 데이터를 1개까지 완벽히 나눠 학습 데이터는 거의 100% 맞지만, 데이터에 섞인 우연한 noise까지 외운 것이라 처음 보는 새 데이터에서는 오히려 성능이 떨어진다(일반화 실패). max_depth로 트리 깊이를 제한하는 등으로 과적합을 막을 수 있다.

채점 포인트

과적합된 것은 Tree Q(매우 깊음).

앞마다 샘플 1개 -> 학습 데이터는 다 맞지만 noise까지 외움.

새 데이터에서 성능 저하(일반화 실패).

해결: max_depth 등으로 깊이 제한.

41. 정답: 데이터 대부분은 일정한 직선 경향을 보이는데, 멀리 동떨어진 점(이상치) 하나가 회귀직선을 그 쪽으로 끌어당겨 직선이 대부분의 점에서 벗어났다. 전처리 단계에서 이런 이상치를 찾아 제거(또는 수정)한 뒤 다시 학습해야 한다.

채점 포인트

원인: 다른 점들과 크게 떨어진 이상치 1개가 회귀직선을 끌어당겼다.

선형회귀는 모든 점과의 오차를 줄이려 하므로 멀리 있는 한 점에도 크게 흔들린다.

해결: 전처리에서 이상치를 찾아 제거/수정한 뒤 다시 학습한다.