


1. 아래 그림은 의사결정트리 5개로 이루어진 랜덤 포레스트가 새 데이터 하나를 분류하는 과정이다. (각 트리는 A 또는 B로 예측)



랜덤 포레스트처럼 여러 트리의 예측을 모아 다수결로 정하는 방식이, 트리 하나만 쓰는 것보다 더 안정적인(믿을 만한) 이유를 그림을 근거로 서술하시오.


2. 의사결정트리 하나를 가지를 끝까지 깊게 키우면 학습 데이터는 거의 다 맞지만 새 데이터에서는 성능이 떨어진다(과적합). 랜덤 포레스트가 이런 과적합에 비교적 강한 이유를, '트리마다 다른 데이터와 특성을 사용한다'는 점과 연결해 서술하시오.

3. 아래는 의사결정트리 5개로 된 랜덤 포레스트가 두 데이터 X1, X2를 분류한 결과 표다.

	Tree1	Tree2	Tree3	Tree4	Tree5
X1	A	A	A	B	A
X2	A	B	A	B	A

(1) X1과 X2의 최종 예측을 각각 다수결로 구하시오. (2) X2처럼 표가 3:2로 갈릴 수 있는데, 트리 개수를 짝수가 아니라 홀수로 두면 좋은 이유를 서술하시오. (범주는 2개)

5. 어떤 학생이 '시험 성적과 관련된 예측은 모두 회귀다'라고 생각한다. 다음 두 작업이 각각 회귀인지 분류인지 구분하고, 그렇게 나뉘는 기준을 서술하시오.




· 작업

- ㄱ. (가) 공부 시간으로 시험 점수(0~100점)를 예측
ㄴ. (나) 공부 시간으로 합격(70점 이상)/불합격을 예측

상황

- ㉠. (1) 메일의 단어/링크 수로 스팸인지 정상인지 가
른다 (스팸/정상 정답 표시 있음)
- ㉡. (2) 집의 면적, 방 수로 집값(원)을 예측한다 (실제
가격 정답 있음)
- ㉢. (3) 고객의 구매 기록만으로 비슷한 고객끼리 묶는
다 (정답 없음)


8. 어떤 모델이 정상 950명, 환자 50명(총 1000명)인 데이터에서 모두 '정상'이라고만 예측했다. 아래는 그 혼동행렬이다. (Neg=정상, Pos=환자. 행=실제, 열=예측)



이 모델의 정확도는 95%로 높다. 그런데도 좋은 모델이라고 할 수 없는 이유를, 혼동행렬의 수치를 근거로 서술하십시오.

[illegible]


9. 여름철 어느 도시에서 '아이스크림 판매량'과 '물놀이 사고 건수'를 조사해 선형회귀를 했더니 결정계수 R^2 가 0.9로 매우 높게 나왔다. 아래는 그 산점도다(색은 그날의 기온).



이 결과를 보고 '아이스크림 판매가 물놀이 사고를 일으킨다'고 결론 내리는 것이 왜 잘못된인지 서술하십시오.

10. k-최근접 이웃(k-NN) 분류에서 k=2로 설정했을 때 분류가 어떻게 이루어지는지, 그리고 어떤 문제가 생길 수 있는지 서술하시오.

11. 아래 산점도의 데이터(class A, B)를 학습에 사용한다. 다음 코드를 읽고 물음에 답하시오.




```

1 from sklearn.neighbors import KNeighborsClassifier
2
3 model = KNeighborsClassifier(n_neighbors=
4     )
5 model.fit(X, y)          # X: 점들의 좌표,
                           # y: 각 점의 클래스(A 또는 B)
6 print(model.predict(4.5, 4.5)) # 새 점 [4.5, 4.5] 분류

```


(1) 이 코드가 사용하는 분류 알고리즘의 이름을 쓰시오.
 (2) 빈칸(n_neighbors)에 들어갈 k값을 정하고, 그렇게 정한 이유를 서술하시오.

12. 두 클래스가 무리를 이룬 산점도에 새 점(빨간 별, ?)을 분류하려고 한다. (전체 데이터는 class A 12개 + class B 8개 = 20개)



값은 $k=2$, $\epsilon=0.1$ 으로 설정했다. 각 설정에서 새 점(?)이 어떤 클래스로 분류될지 예상하고, 둘 중 더 잘못된 설정이 무엇인지 이유와 함께 서술하시오.


13. 아래 산점도에서 class A 무리 쪽에 class B 점 하나가 섞여 있다(노이즈/이상치). 새 점(빨간 별, ?)을 분류하려고 한다.



새 점(?)을 $k=1$ 과 $k=3$ 으로 분류하면 각각 어떤 클래스가 되는지 예상하고, $k=1$ 을 쓸 때의 위험을 서술하시오.

14. k -최근접 이웃(k -NN) 분류에서 k 값을 보통 홀수로 정하는 이유를 서술하시오. (클래스는 2개라고 가정한다.)

17. 같은 종류의 데이터에 각각 선형회귀(빨간 직선)를 적용한 두 그래프 A, B다. (R^2 는 결정계수)



A와 B 중 예측 성능이 더 좋은 쪽을 고르고, 그렇게 판단한 근거와 성능이 낮은 쪽이 왜 낮은지 서술하시오.

18. 다음 코드를 읽고 물음에 답하시오.

```
1 from sklearn.linear_model import LinearRegression
2
3 model = LinearRegression()
4 model.fit(X, y)          # X: 공부 시간, y: 시험 점수
5 print(model.predict( 7 )) # 공부 7시간일 때
```


이 코드가 무엇을 예측하는지 쓰고, 그 예측 결과가 분류와 회귀 중 어느 것에 해당하는지 이유와 함께 서술하시오.

25. 머신러닝으로 문제를 해결하는 전체 과정을, 데이터를 준비하는 단계부터 모델 성능을 확인하는 단계까지 순서대로 서술하시오.

27. 로지스틱회귀는 이름에 '회귀'가 들어가 있어 회귀(숫자 예측)로 오해하기 쉽지만, 실제로는 분류 알고리즘이다. 로지스틱회귀가 회귀가 아니라 분류인 이유를 서술하시오.


26. R2(결정계수)는 회귀 모델의 성능을 나타내는 지표다. R2가 무엇을 의미하는지, 그리고 값이 1에 가까울 때와 0에 가까울 때가 각각 어떤 상태인지 서술하시오.

28. 아래 산점도에서 새 점(빨간 별, ?)은 두 클래스 무리 사이 경계 부근에 있다.



이 새 점의 분류가 다른 점들보다 불확실한 이유를 쓰고, k를 너무 작게(k=1) 잡을 때와 적절히 키울 때의 차이를 서술하시오.


29. 두 특성 annual_income(0~1000)과 rating(0~10)으로 k-NN 분류를 하려고 한다. 아래 산점도와 코드를 보시오.



```
1 from sklearn.neighbors import KNeighborsClassifier
2 model = KNeighborsClassifier(n_neighbors=3)
3 model.fit(X, y) # X의 두 특성: annual_income(0~1000), rating(0~10)
4 print(model.predict(500, 5.2))
```


두 특성의 값 범위가 크게 다른 상태로 k-NN을 적용하면 어떤 문제가 생기는지와 그 해결 방법을 서술하시오.

30. class A가 16개, class B가 5개인 불균형 데이터다. 새 점(?)은 B 무리에 가깝다.




k를 아주 크게(예: k=15) 잡으면 새 점이 어떤 클래스로 분류될지 예상하고, 그 이유를 서술하시오.

31. 아래 그림에서 새 점(?)으로부터 가장 가까운 이웃 4개가 class A 2개, class B 2개로 같은 거리에 있다.




k=4로 분류하면 어떤 문제가 생기는지, 그리고 이 문제를 어떻게 해결할 수 있는지 서술하시오.

32. 세 클래스(A, B, C)의 데이터가 있고 새 점(?)을 분류하려고 한다.




k=3으로 분류할 때 클래스를 정하는 방법을 설명하고, 그림을 근거로 새 점이 어느 클래스로 분류될지 쓰시오.

33. 새 점(?)이 두 무리의 정확히 중간(대칭 위치)에 있다.




이 위치에서 $k=1$ 로 분류할 때의 문제와, 이런 애매한 위치에서 k -NN 분류가 갖는 한계를 서술하시오.

34. 같은 데이터에 k-Means를 적용하는데, 초기 중심점(빨간 X) 위치만 다르게 두 번 실행했다(start A, start B).




두 실행의 최종 결과가 달라질 수 있는 이유와, 결과를 매번 똑같이 만드는 방법을 서술하시오.

35. 아래 산점도의 점들에 k-Means 군집화를 적용하려고 한다.




적절한 군집 개수 k 를 정하고, 그렇게 정한 근거를 서술하시오.

36. 점은 세 무리로 보이는데 $k=2$ 로 군집화한 결과다(색이 군집을 나타냄). 아래 두 무리가 같은 색(한 군집)으로 묶였다.




이 결과에서 어떤 일이 일어났는지 설명하고, 적절한 k 가 몇이어야 하는지 쓰시오.

37. 초기 중심점 center1(2,2), center2(5,5)와 7개의 점이 아래와 같이 있다.




(1) 각 점을 더 가까운 중심점에 배정하고, (2) 각 군집에 모인 점들의 평균으로 옮긴 새 중심점 좌표를 두 개 모두 구하시오.

38. 왼쪽은 색(정답)이 없는 데이터, 오른쪽은 색(정답)이 있는 데이터다.




k-Means는 둘 중 어느 상황의 학습에 해당하며, 그렇게 판단하는 이유를 서술하시오.

39. 사람 눈에는 위/아래 두 줄(띠)로 보이는, 가로로 길게 늘어선 데이터다.




이 데이터에 k-Means(k=2)를 적용하면 위/아래 두 줄로 잘 나누지 못할 수 있다. 그 이유를 서술하시오.

40. 다음은 메일을 Ham(정상)/Spam(스팸)으로 분류하는 의사결정트리다. (links: 링크 수, caps: 대문자 비율%)




입력 links=8, caps=70 이 트리를 따라 분류되는 과정을 분기별로 순서대로 쓰고, 최종 분류 결과를 서술하시오.

43. 다음 의사결정트리는 맨 위(루트)에서 study_hours로 먼저 나눈다.




study_hours가 다른 특성보다 중요하게 쓰였다고 볼 수 있는 이유를 서술하시오.

44. 어떤 데이터에 선형회귀(빨간 직선)를 적용했더니 결정계수 R2가 0.05로 매우 낮게 나왔다.




데이터의 분포 모양에 주목하여, R2가 이렇게 낮은 이유를 서술하시오.

45. 학습 데이터는 $x=1\sim 10$ 범위인데, 회귀직선을 그대로 연장해 $x=20$ 일 때의 값을 예측했다(빨간 별).




이 $x=20$ 에 대한 예측을 그대로 믿기 어려운 이유를 서술하시오.

46. 같은 종류의 데이터에 각각 선형회귀를 적용한 두 그래프 A, B다.




두 그래프 중 결정계수 R^2 가 더 높은 쪽을 고르고, 그렇게 판단한 근거를 서술하시오.

47. 아래 그래프에서 회색 수직선은 각 점과 회귀직선 사이의 세로 거리(잔차)를 나타낸다.



선형회귀가 직선의 기울기와 절편을 정할 때 이 잔차들을 어떻게 사용하는지 서술하시오.

48. 두 그래프 A, B의 회귀직선은 기울기의 부호가 서로 다르다.



각 그래프에서 x와 y가 어떤 관계인지 기울기 부호를 근거로 서술하시오.

49. 다음은 스팸 필터의 혼동행렬이다. (Ham=정상 메일, Spam=스팸. 행=실제, 열=예측)

actual	Actual: Ham	35	15
	Actual: Spam	3	47
		Pred: Ham	Pred: Spam
		predicted	

이 필터를 사용할 때 사용자가 겪는 가장 곤란한 문제가 무엇인지, 혼동행렬의 수치를 근거로 서술하시오.

50. 실제 정상(Neg)이 990개, 양성(Pos)이 10개인 매우 불균형한 데이터의 혼동행렬이다.

actual	Actual: Neg	985	5
	Actual: Pos	8	2
		Pred: Neg	Pred: Pos
		predicted	

이 모델의 정확도를 구하고, 정확도만으로 이 모델을 좋다고 할 수 없는 이유를 서술하시오.

51. 다음 혼동행렬을 보고 물음에 답하시오. (행=실제, 열=예측)

actual	Actual: Neg	50	10
	Actual: Pos	20	40
		Pred: Neg	Pred: Pos
		predicted	

이 모델의 정확도(accuracy)를 구하는 식과 과정을 쓰고, 값을 백분율로 구하시오.

52. 두 모델 X, Y의 혼동행렬이다. (Pos=질병 있음. 행=실제, 열=예측)

		Model X				Model Y	
actual	Actual: Neg	60	30	actual	Actual: Neg	88	2
	Actual: Pos	2	28		Actual: Pos	18	12
		Pred: Neg	Pred: Pos			Pred: Neg	Pred: Pos
		predicted				predicted	

암 진단처럼 실제 환자(Pos)를 놓치면 안 되는 상황에서 어느 모델이 더 적합한지, 위음성(실제 양성을 음성으로 판정)을 근거로 서술하시오.

1. 정답: 트리 하나는 우연히 학습 데이터의 잡음에 휘둘러 틀린 예측을 할 수 있다. 그림에서도 Tree 3은 B로 잘못 예측했지만, 나머지 4개 트리가 A로 예측해 다수결 결과는 A로 올바르게 나왔다. 이처럼 서로 조금씩 다른 여러 트리의 예측을 모으면 개별 트리의 실수가 다수에 의해 상쇄되어, 한 트리만 쓸 때보다 예측이 안정적이고 과적합에 강해진다.

채점 포인트

단일 트리는 잡음/우연으로 틀릴 수 있음.

그림: Tree 3만 B(오답), 나머지 4개 A -> 다수결 A로 교정.

여러 트리의 실수가 서로 상쇄(양상불 효과) -> 더 안정적, 과적합에 강함.

'개별 오류가 다수결로 상쇄된다'가 들어가면 정답.

2. 정답: 랜덤 포레스트는 각 트리를 만들 때 전체 데이터에서 일부를 무작위로 뽑고(중복 허용), 사용할 특성도 일부만 무작위로 골라 학습시킨다. 그래서 트리마다 서로 다른 관점으로 조금씩 다르게 학습되어, 특정 데이터의 잡음에 모든 트리가 함께 과적합되지 않는다. 이렇게 서로 다른 트리들의 예측을 다수결/평균으로 합치면 한 트리가 외운 잡음은 묻히고 공통된 패턴만 남아, 단일 트리보다 과적합에 강하다.

채점 포인트

각 트리: 데이터 일부(무작위, 중복허용) + 특성 일부(무작위)로 학습 -> 트리마다 다름.

트리들이 같은 잡음에 함께 과적합되지 않음.

예측을 모으면 개별 잡음은 상쇄되고 공통 패턴만 남음.

'트리마다 다르게 학습 + 모아서 잡음 상쇄'가 핵심.

3. 정답: (1) X1은 A가 4표, B가 1표이므로 최종 A. X2는 A가 3표, B가 2표이므로 최종 A. (2) 범주가 2개일 때 트리 개수가 홀수이면 두 범주의 표가 동점이 될 수 없어 다수결이 항상 한쪽으로 정해진다. 짝수면 2:2처럼 동점이 나와 어느 쪽으로 결정할지 모호해지는 상황이 생길 수 있다.

채점 포인트

X1: 4:1 -> A. X2: 3:2 -> A.

홀수 트리: 2범주에서 동점 불가 -> 항상 다수결 결정 가능.

짝수면 동점(예: 2:2) 발생 가능 -> 결정 모호.

(1) 두 최종예측 + (2) 동점 회피 이유가 들어가면 정답.

4. 정답: (1) 정답(스팸/정상)이 있으므로 지도학습이고, 예측 대상이 범주이므로 분류다. 예: 의사결정트리, k-NN, 로지스틱회귀, 랜덤 포레스트 중 하나. (2) 정답(가격)이 있으므로 지도학습이고, 예측 대상이 연속적인 숫자이므로 회귀다. 예: 선형회귀. (3) 정답이 없으므로 비지도학습이고, 비슷한 것끼리 묶으므로 군집이다. 예: k-Means.

채점 포인트

맵 1단계(정답 있나?): (1)(2) 있음 -> 지도, (3) 없음 -> 비지도.

맵 2단계(지도일 때 숫자/범주?): (1) 범주 -> 분류, (2) 숫자 -> 회귀.

(3) 비지도 + 묶기 -> 군집(k-Means).

세 상황 모두 (지도/비지도)+(회귀/분류/군집)+알고리즘 예가 맞으면 정답.

6. 정답: 1) 입력 특성들을 식에 넣어 하나의 값(z)을 계산한다. 2) 그 값을 로지스틱(시그모이드) 함수에 통과시켜 0~1 사이의 확률로 바꾼다. 3) 이 확률을 기준값 0.5와 비교한다. 4) 확률이 0.5보다 크면 class 1, 작으면 class 0으로 판정한다. 즉 연속적인 확률을 구한 뒤 기준으로 잘라 범주를 정하므로 결과가 범주(분류)다.

채점 포인트

입력 -> 값(z) 계산 -> 시그모이드로 0~1 확률 변환.

확률을 0.5와 비교: >0.5 면 class 1, <0.5 면 class 0.

연속 확률을 기준으로 잘라 범주 결정 -> 분류.

'확률 -> 0.5 기준 -> 범주'의 흐름이 들어가면 정답.

5. 정답: (가)는 회귀다. 0~100 사이의 연속적인 숫자(점수)를 예측하기 때문이다. (나)는 분류다. 합격/불합격이라는 정해진 범주 중 하나를 예측하기 때문이다. 회귀와 분류를 가르는 기준은 예측 대상이 '연속적인 숫자인가(회귀)' 아니면 '정해진 범주인가(분류)'이며, 같은 성적 주제라도 무엇을 예측하느냐에 따라 달라진다.

채점 포인트

(가) 점수(연속 숫자) 예측 -> 회귀.

(나) 합격/불합격(범주) 예측 -> 분류.

기준: 출력이 숫자면 회귀, 범주면 분류.

'주제가 아니라 예측 대상의 형태로 나뉜다'가 핵심.

7. 정답: P1은 확률 0.85로 0.5보다 크므로 class 1, P3는 0.20으로 0.5보다 작으므로 class 0으로 분류한다. P2는 0.45로 0.5보다 약간 작아 class 0으로 분류되지만, 확률이 0.5에 매우 가까워 모델이 두 범주를 거의 반반으로 본 것이므로 이 예측은 강하게 신뢰하기 어렵다(경계에 가까운 불확실한 예측).

채점 포인트

0.5 초과면 class 1, 미만이면 class 0.

P1=0.85 -> class 1, P3=0.20 -> class 0, P2=0.45 -> class 0.

P2는 0.5에 근접 -> 확신이 낮은(경계) 예측.

세 분류 결과 + P2 불확실성 언급이 들어가면 정답.

8. 정답: 이 모델은 모두 정상으로만 찍었기 때문에 정상 950명은 다 맞춰 정확도가 $950/1000 = 95\%$ 로 높게 나온다. 하지만 정작 찾아내야 할 환자 50명은 한 명도 맞히지 못했다(전부 정상으로 분류). 이처럼 한 범주가 압도적으로 많은 불균형 데이터에서는 다수 범주만 찍어도 정확도가 높게 나와 모델의 실제 쓸모를 가린다. 환자를 한 명도 못 잡으므로 진단 모델로는 쓸모가 없으며, 정확도 대신 환자를 얼마나 잡았는지(재현율)나 혼동행렬을 함께 봐야 한다.

채점 포인트

정확도 95% = 정상 950명을 다 맞혀서 나온 수치.

환자 50명은 0명 적중(전부 정상으로 분류).

불균형 데이터에서 다수만 찍어도 정확도 높음 -> 정확도가 함정.

'중요한 소수(환자)를 못 잡는다 + 정확도만으론 안 됨'이 핵심.

9. 정답: R2가 높다는 것은 두 값이 함께 늘고 주는 관계(상관관계)가 강하다는 뜻일 뿐, 한쪽이 다른 쪽의 원인이라는 뜻(인과관계)은 아니다. 여기서는 '기온(여름 더위)'이라는 숨은 공통 원인이 있어, 더울수록 아이스크림도 많이 팔리고 물놀이도 늘어 사고도 함께 증가한 것이다. 두 변수는 공통 원인 때문에 같이 움직였을 뿐 서로 원인-결과가 아니므로, R2가 높다고 인과관계로 단정하면 안 된다.

채점 포인트

R2/상관이 높다 = 같이 움직인다(상관)일 뿐, 인과 아님.

숨은 공통 원인: 기온(여름). 더위 -> 아이스크림 판매 + 물놀이/사고 둘 다 증가.

상관관계 != 인과관계 가 핵심.

'숨은 변수(기온) 때문에 함께 움직였다'가 들어가면 정답.

10. 정답: 가장 가까운 2개의 다수결로 분류하지만, 두 이웃의 클래스가 다르면 1:1 동점이 되어 분류를 정할 수 없다(짝수 k의 동점 문제). 그래서 k는 보통 홀수로 둔다.

채점 포인트

새 데이터에서 가장 가까운 이웃 2개를 찾는다.

그 2개의 클래스를 다수결(투표)한다.

두 이웃의 클래스가 서로 다르면 1:1 동점 -> 다수결로 결정 불가.

결론: 짝수 k(특히 2)는 동점이 생길 수 있어, k는 홀수가 바람직하다.

11. 정답: (1) k-NN(k-최근접 이웃). (2) 예: k=3 또는 5.
 짝수는 동점이 생기므로 홀수가 좋고, k=1은 이상치/노이즈에 민감, k가 너무 크면 멀리 있는 점까지 포함되어 클래스 경계가 흐려진다. 데이터가 두 무리로 비교적 잘 나뉘므로 작은 홀수면 충분하다.

채점 포인트

- (1) KNeighborsClassifier는 k-NN(k-최근접 이웃) 분류기다.
- (2) 핵심 근거 3가지가 들어가면 정답 인정:
 - 홀수 권장(짝수는 동점).
 - k=1처럼 너무 작으면 노이즈/이상치 하나에 휘둘림.
 - k가 너무 크면 먼 점까지 포함 -> 경계가 흐려지고 다수 클래스로 쏠림.
- 구체적 k 숫자(예: 3, 5)는 위 이유와 함께면 정답.

12. 정답: k=2: 가장 가까운 2개가 모두 class B이므로 B로 분류된다(동작은 정상이지만, 짝수 k는 동점이 생길 수 있어 일반적으로 권장되지 않는다). k=100: 전체 데이터가 20개뿐이라 이웃을 100개 볼 수 없고, 설령 전체를 본다고 해도 다수 클래스 A로만 분류되어 새 점의 위치(B에 가까움)가 무시된다. 따라서 둘 중 더 잘못된 설정은 k=100이다.

채점 포인트

새 점은 class B 무리에 확실히 가깝다.

k=2: 가장 가까운 2개가 모두 B -> B로 분류(위치는 반영). 다만 짝수 k라 동점 위험이 있어 이상적이진 않다.

k=100: 전체가 20개라 이웃 100개는 불가능(데이터 수 초과).

설령 전체를 이웃으로 보면 다수인 A로만 분류 -> 새 점 위치가 전혀 반영 안 됨.

결론: k=2는 사소한 결함(짝수)일 뿐이지만 k=100은 위치 정보를 통째로 잃는 근본적 오류 -> 더 잘못된 것은 k=100.

13. 정답: $k=1$: 가장 가까운 1개가 A 무리에 섞인 B 이상치이므로 B로 분류된다(오분류). $k=3$: 가까운 3개는 B 이상치 1개 + 주변 A 2개라 A로 분류된다(정상). $k=1$ 은 가장 가까운 한 점만 보기 때문에 그 점이 노이즈/이상치면 그대로 오분류된다(이상치에 매우 민감, 과적합). k 를 키우면 주변 다수로 보정된다.

채점 포인트

새 점은 실제로는 A 무리 영역에 있다.

$k=1$: 가장 가까운 한 점이 하필 섞여 있던 B 이상치 -> B로 오분류.

$k=3$: 가까운 3개 = B 이상치 1 + A 2 -> 다수결로 A(정상 분류).

결론: $k=1$ 은 가장 가까운 한 점에만 의존해 노이즈/이상치 하나에 휘둘린다(과적합).

k 를 적당히 키우면 주변 여러 점의 다수결로 이상치 영향을 줄일 수 있다.

15. 정답: 1) 중심점 2개를 무작위 위치에 정한다(초기화). 2) 각 점을 더 가까운 중심점에 배정해 2개 그룹을 만든다. 3) 각 그룹에 속한 점들의 평균 위치로 중심점을 옮긴다(재설정). 4) 배정과 이동을 더 이상 변화가 없을 때까지 반복하고 멈춘다. 결과로 데이터가 2개 군집으로 나뉜다.

채점 포인트

초기화: 중심점(centroid)을 $k=2$ 개, 보통 무작위 위치에 둔다.

배정: 각 점을 더 가까운 중심점 쪽으로 보내 2개 그룹을 만든다.

재설정: 각 그룹 점들의 평균으로 중심점을 이동한다.

반복/종료: 배정->이동을 변화가 없을 때까지 반복한다.

4단계(초기화/배정/재설정/반복종료)가 들어가면 정답.

14. 정답: k 가 짝수이면 두 클래스의 이웃 수가 같아지는 동점(예: 2:2, 3:3)이 생길 수 있어 어느 쪽으로 분류할지 정할 수 없다. k 를 홀수로 하면 두 클래스의 표 합이 홀수라 같아질 수 없으므로 항상 한쪽이 다수가 되어 분류가 결정된다.

채점 포인트

이웃들의 클래스를 다수결로 분류한다.

클래스가 2개일 때 k 가 짝수면 표가 반반(예: 2:2)이 되는 동점이 가능하다.

동점이면 다수결로 클래스를 정할 수 없다.

k 가 홀수면 두 클래스의 표 합이 홀수라 같아질 수 없으므로 항상 다수가 정해진다.

16. 정답: (1) 비지도학습 (정답 y 없이 X만 사용하고 `fit_predict`로 군집을 찾음). (2) $k=3$ (점들이 세 무리로 뚜렷이 뭉쳐 있으므로). (3) 전체 데이터가 24개뿐이라 군집을 100개 만들 수 없다. 점이 하나도 없는 빈 군집이 생겨 에러가 나거나, 사실상 점마다 따로 나뉘어 군집화가 무의미해진다.

채점 포인트

- (1) X(좌표)만 있고 정답 y가 없으며 `fit_predict`로 묶음 -> 비지도학습.
- (2) 산점도에 점 무리가 3개 -> $k=3$.
- (3) 전체 점이 24개인데 $k=100$ 이면 데이터 수보다 군집이 많다.
-> 빈 군집 발생(에러) / 군집화가 의미를 잃음.

18. 정답: 공부 시간(X)으로 시험 점수(y)를, 특히 7시간 공부했을 때의 예상 점수를 예측한다. 예측 결과는 숫자(회귀)다. 시험 점수처럼 연속적인 수치를 예측하므로 회귀이며, 범주(합격/불합격 등)를 고르는 분류와 다르다.

채점 포인트

`fit(X, y)`로 공부시간-점수 관계를 학습하고 `predict(7)`로 7시간일 때 점수를 예측.
점수는 연속적인 숫자 -> 회귀(LinearRegression).
범주를 고르는 분류와 구분되면 정답.

17. 정답: $B(R^2=0.94)$ 가 $A(R^2=0.34)$ 보다 성능이 좋다. R^2 가 1에 가까울수록 점들이 직선에 가깝게 모여 예측이 잘 맞기 때문이다. A는 점들이 직선에서 멀리 넓게 흩어져 있어(분산이 큼) 직선으로 예측하기 어려워 R^2 가 낮다.

채점 포인트

- R^2 (결정계수)는 1에 가까울수록 데이터가 직선에 잘 맞는다는 뜻.
- B의 $R^2(0.94)$ 가 A의 $R^2(0.34)$ 보다 크므로 B가 성능이 좋다.
- A가 낮은 이유: 점들이 직선에서 멀리 흩어져 있어(큰 분산) 직선이 잘 설명하지 못한다.
- (이상치/비선형 관계도 R^2 를 낮추는 원인으로 언급하면 가점)

19. 정답: 데이터 대부분은 일정한 직선 경향을 보이는데, 멀리 동떨어진 점(이상치) 하나가 회귀직선을 그 쪽으로 끌어당겨 직선이 대부분의 점에서 벗어났다. 전처리 단계에서 이런 이상치를 찾아 제거(또는 수정)한 뒤 다시 학습해야 한다.

채점 포인트

원인: 다른 점들과 크게 떨어진 이상치 1개가 회귀직선을 끌어당겼다.
선형회귀는 모든 점과의 오차를 줄이려 하므로 멀리 있는 한 점에도 크게 흔들린다.
해결: 전처리에서 이상치를 찾아 제거/수정한 뒤 다시 학습한다.

20. 정답: 선형회귀: 지도학습·회귀 / 로지스틱회귀: 지도 학습·분류 / k-NN: 지도학습·분류 / 의사결정트리: 지도 학습·분류 / k-Means: 비지도학습·군집

채점 포인트

지도/비지도: 정답(레이블)을 쓰면 지도, 안 쓰면 비지도.

회귀=숫자 예측, 분류=범주 예측, 군집=정답 없이 그룹화.

ㄱ 선형회귀: 지도·회귀. ㄴ 로지스틱회귀: 지도·분류(이름은 회귀지만 분류).

ㄷ k-NN: 지도·분류. ㄹ 의사결정트리: 지도·분류. ㅁ k-Means: 비지도·군집.

22. 정답: `fillna(df['math'].mean())`: math 열의 빈 값(결측치)을 그 열의 평균으로 채운다 - 빈 값이 있으면 학습이 안 되므로. `dropna()`: 아직 남아 있는 결측치가 있는 행을 제거한다 - 불완전한 데이터를 빼기 위해. `df[df['score'] <= 100]`: 점수가 100을 넘는 비정상 값(이상치)을 걸러낸다 - 잘못된 데이터가 결과를 왜곡하지 않도록. 즉 결측치와 이상치를 정리해 모델이 올바른 데이터로 학습하게 한다.

채점 포인트

2줄 `fillna(mean)`: 결측치를 평균으로 대체.

3줄 `dropna`: 남은 결측치 행 제거.

4줄 조건 필터: `score>100` 같은 이상치 제거.

공통 이유: 결측치/이상치가 있으면 학습이 안 되거나 결과가 왜곡됨.

21. 정답: k-NN은 지도학습 분류 알고리즘으로, 정답이 있는 데이터를 이용해 새 데이터를 가장 가까운 이웃들의 다수결로 분류한다. 여기서 k는 '참고할 이웃의 수'다. k-Means는 비지도학습 군집 알고리즘으로, 정답 없이 비슷한 데이터끼리 묶는다. 여기서 k는 '나눌 군집(중심점)의 개수'다.

채점 포인트

지도/비지도: k-NN은 지도(정답 사용), k-Means는 비지도(정답 없음).

하는 일: k-NN은 분류, k-Means는 군집.

k의 의미: k-NN은 이웃 수, k-Means는 군집 수.

세 측면이 모두 들어가면 정답.

23. 정답: 학습에 사용하지 않은 새 데이터(test)로 평가해야, 모델이 처음 보는 데이터에도 잘 작동하는지(일반화) 확인할 수 있다. 학습에 쓴 데이터로만 평가하면 모델이 그 데이터를 외운 것일 수 있어 실제 성능을 제대로 알 수 없다.

채점 포인트

test는 학습에 안 쓴 데이터 -> 새 데이터에 대한 성능(일반화) 측정.

train으로만 평가하면 외워서 잘 맞는 것과 구분이 안 됨.

'일반화 확인'(또는 새 데이터 성능)이 들어가면 정답.

24. 정답: 실제 암 환자(Pos) 28명 중 13명을 음성(Neg)으로 잘못 판정했다(위음성). 암 진단에서 위음성은 암 환자를 놓쳐 치료 시기를 놓치게 하는 치명적 오류다. 전체 정확도는 $(80+15)/120 \approx 79\%$ 로 나쁘지 않아 보이지만, 정작 암 환자의 약 46%(13/28)를 놓치므로 진단 모델로는 위험하다. 위음성을 줄이는 방향으로 개선해야 한다.

채점 포인트

혼동행렬 읽기: 실제 Pos(암) = 13(위음성) + 15(맞춤) = 28명.

위음성(FN)=13: 실제 암인데 음성으로 판정 -> 환자를 놓침.

암 진단에서는 위음성이 위양성보다 훨씬 위험하다(치료 시기 놓침).

정확도(약 79%)만 보면 괜찮아 보여도 암 환자를 절반 가까이 놓침 -> 부적합.

핵심: '위음성이 많아 암 환자를 놓친다'가 들어가면 정답.

25. 정답: 1) 데이터 로드: csv 등에서 데이터를 불러온다. 2) 전처리: 결측치·이상치를 정리하는 등 데이터를 학습에 맞게 다듬는다. 3) 데이터 분리: train(학습용)과 test(평가용)로 나눈다. 4) 학습(fit): train 데이터로 모델을 학습시킨다. 5) 예측/평가: test 데이터로 예측하고 R2(회귀)·정확도(분류) 등으로 성능을 평가한다.

채점 포인트

데이터 로드 -> 전처리 -> (train/test 분리) -> 학습(fit) -> 예측/평가 순서.

전처리(결측치·이상치 정리)와 학습/평가 단계가 들어가야 함.

순서가 맞고 각 단계가 무엇을 하는지 설명되면 정답.

26. 정답: R2(결정계수)는 회귀 모델이 데이터의 경향을 얼마나 잘 설명(예측)하는지를 보통 0~1 사이로 나타낸 값이다. 1에 가까울수록 점들이 회귀직선에 가깝게 모여 예측이 잘 맞고, 0에 가까울수록 직선이 데이터를 잘 설명하지 못해 예측이 부정확하다.

채점 포인트

R2는 회귀의 예측 성능(직선이 데이터를 얼마나 설명하는지)을 나타낸다.

보통 0~1 범위, 1에 가까울수록 좋음(직선에 잘 맞춤).

0에 가까우면 직선이 데이터를 설명하지 못함(성능 나쁨).

27. 정답: 로지스틱회귀는 연속적인 숫자를 예측하는 것이 아니라, 데이터가 어느 범주(예: 합격/불합격, 양성/음성)에 속하는지를 구분한다. 로지스틱 함수로 0~1 사이 값(확률)을 구한 뒤 기준(보통 0.5)으로 범주를 나누므로 결과가 범주다. 따라서 이름과 달리 분류 알고리즘이다.

채점 포인트

회귀=숫자 예측, 분류=범주 예측.

로지스틱회귀의 결과는 숫자가 아니라 범주(예: 0/1, 합격/불합격).

로지스틱 함수로 확률(0~1)을 구하고 기준으로 나눠 범주를 정함 -> 분류.

'이름은 회귀지만 출력이 범주라 분류'가 핵심.

29. 정답: k-NN은 거리로 이웃을 찾는데, 값의 범위가 큰 `annual_income(0~1000)`이 거리를 거의 결정해버려 범위가 작은 `rating(0~10)`은 사실상 무시된다. 두 특성을 같은 기준으로 맞추는 표준화(스케일링, 예: `StandardScaler`)를 적용해 각 특성이 거리에 공평하게 반영되도록 해야 한다.

채점 포인트

거리 계산에서 범위가 큰 특성(`income`)이 지배 -> 작은 특성(`rating`)이 무시됨.

해결: 표준화/정규화(스케일링)로 두 특성 범위를 맞춤.

스케일링 후 각 특성이 거리에 공평하게 기여.

28. 정답: 새 점이 두 무리의 경계 부근에 있어, 가까운 이웃에 두 클래스가 섞여 있을 수 있어 어느 쪽으로도 단정하기 어렵다. $k=1$ 은 가장 가까운 한 점에만 의존해 그 점의 클래스에 따라 결과가 쉽게 흔들린다(불안정). k 를 적당히 키우면 주변 여러 점의 다수결로 결정하므로 더 안정적으로 분류된다.

채점 포인트

경계 부근이라 가까운 이웃에 두 클래스가 섞여 분류가 모호하다.

$k=1$: 가장 가까운 한 점에 좌우됨 -> 불안정/노이즈에 민감.

k 를 키우면 주변 다수결로 더 안정적으로 분류.

30. 정답: A로 분류될 가능성이 크다. k 를 크게 잡으면 멀리 있는 점까지 이웃에 포함되는데, 전체에 A가 훨씬 많아 (16 대 5) 다수결이 A로 쏠리기 때문이다. 그래서 새 점이 실제로는 B 무리에 가깝게도 A로 잘못 분류될 수 있다. 데이터가 불균형할 때 너무 큰 k 는 다수 클래스로 쏠리는 위험이 있다.

채점 포인트

큰 k -> 멀리 있는 점까지 이웃에 포함.

전체에 A가 많아 다수결이 A로 쏠림 -> B 근처인데도 A로 오분류.

불균형 데이터에서 과도하게 큰 k 의 위험.

31. 정답: 가장 가까운 4개가 A 2개, B 2개로 2:2 동점이
라 다수결로 클래스를 정할 수 없다. k 를 홀수(예: 3 또는
5)로 바꾸면 두 클래스의 표 합이 홀수가 되어 갈라질 수
없으므로 동점이 사라지고 분류가 결정된다.

채점 포인트

A 2 : B 2 동점 -> 다수결 불가.

짝수 k (특히 클래스 2개)에서 동점이 생길 수 있음.

해결: k 를 홀수로 설정.

32. 정답: 새 점에서 가장 가까운 이웃 3개를 찾아 그 클레
스를 다수결로 정한다. 새 점은 class B 무리에 가장 가까
우므로 가까운 3개가 대부분 B여서 B로 분류된다. 클래스
가 3개여도 다수결 방식은 동일하다.

채점 포인트

가장 가까운 $k(=3)$ 개 이웃의 다수결로 결정.

새 점은 B 무리에 가장 가까움 -> B로 분류.

클래스가 여러 개여도 다수결 원리는 같다.

33. 정답: 정중앙이라 두 무리까지의 거리가 거의 같아서,
가장 가까운 한 점($k=1$)이 어느 무리의 점이나에 따라 결
과가 쉽게 뒤바뀐다(불안정). 이렇게 경계의 애매한 위치에
서는 k 를 키워도 양쪽 무리가 비슷하게 이웃에 포함되어
어느 쪽이라고 확신하기 어렵다. 즉 k -NN은 경계 부근의
점을 안정적으로 분류하기 어렵다.

채점 포인트

두 무리까지 거리가 비슷 -> $k=1$ 은 한 점에 좌우되어
불안정.

k 를 키워도 양쪽이 비슷하게 포함되어 확신 낮음.

경계 부근 점은 k -NN으로 안정적 분류가 어렵다.

34. 정답: k -Means는 처음 중심점을 보통 무작위로 정하
는데, 시작 위치가 다르면 점들이 서로 다른 군집으로 배정
되어 반복 결과(최종 군집)가 달라질 수 있다.
`random_state(시드)`를 지정하면 초기 중심이 항상 같은
위치로 정해져 결과를 똑같이 재현할 수 있다.

채점 포인트

초기 중심이 무작위라 시작 위치에 따라 결과가 달라
질 수 있음(초기화 의존).

해결: `random_state(시드)` 고정 -> 초기 중심 고정 ->
재현 가능.

35. 정답: $k=3$ 이 적절하다. 점들이 세 무리로 뚜렷하게 뭉쳐 있으므로 군집 개수를 데이터가 자연스럽게 나뉘는 무리의 수인 3에 맞추는 것이 좋다.

채점 포인트

점들이 3개 무리로 뚜렷이 뭉쳐 있음.

k 는 데이터가 자연스럽게 나뉘는 무리 수에 맞춤 $\rightarrow k=3$.

37. 정답: (1) 배정: $\text{center1} \leftarrow (1,1), (1,2), (2,1) / \text{center2} \leftarrow (6,6), (7,6), (6,7), (7,7)$. (2) 새 중심: $\text{center1} = ((1+1+2)/3, (1+2+1)/3) = (\text{약 } 1.33, \text{약 } 1.33)$. $\text{center2} = ((6+7+6+7)/4, (6+6+7+7)/4) = (6.5, 6.5)$.

채점 포인트

각 점을 더 가까운 중심에 배정: 좌하 3개 $\rightarrow \text{center1}$, 우상 4개 $\rightarrow \text{center2}$.

center1 평균 = $(4/3, 4/3) = \text{약 } (1.33, 1.33)$.

center2 평균 = $(26/4, 26/4) = (6.5, 6.5)$.

36. 정답: 군집을 2개만 만들도록 했기 때문에, 서로 가까운 아래 두 무리가 하나의 군집으로 강제로 합쳐졌다. 실제 무리는 3개이므로 $k=3$ 으로 해야 세 무리가 각각 제대로 나뉜다.

채점 포인트

$k=2$ 라 가까운 두 무리가 한 군집으로 강제 병합됨.

무리가 3개 $\rightarrow$ 적절한 $k=3$.

38. 정답: 왼쪽처럼 정답(레이블)이 없는 데이터를 다루는 비지도학습이다. k-Means는 정답을 주지 않고 데이터의 분포(점들이 가까운 정도)만 보고 비슷한 것끼리 묶어 군집을 찾기 때문이다.

채점 포인트

k-Means는 정답(y) 없이 데이터만으로 묶음 $\rightarrow$ 비지도 학습(왼쪽).

분포만 보고 비슷한 것끼리 군집화.

39. 정답: k-Means는 중심점까지의 거리로 점을 묶어 둥근(구형) 모양의 군집을 가정한다. 가로로 긴 띠에서는 같은 줄 안에서도 좌우 끝이 서로 멀고, 위아래 줄이 오히려 가까운 구간이 있다. 그래서 거리 기준으로는 위/아래가 아니라 좌/우로 잘리는 식으로 엉뚱하게 나뉠 수 있다.

채점 포인트

k-Means는 중심 거리 기반이라 둥근 군집을 가정.

긴 띠는 같은 줄 좌우가 멀고 위아래가 가까워 좌/우로 잘릴 수 있음.

모양이 길쭉하거나 겹친 분포에서 k-Means의 한계.

41. 정답: Tree Q가 과적합되었다. 앞마다 학습 데이터를 1개까지 완벽히 나눠 학습 데이터는 거의 100% 맞히지만, 데이터에 섞인 우연한 noise까지 외운 것이라 처음 보는 새 데이터에서는 오히려 성능이 떨어진다(일반화 실패). max_depth로 트리 깊이를 제한하는 등으로 과적합을 막을 수 있다.

채점 포인트

과적합된 것은 Tree Q(매우 깊음).

앞마다 샘플 1개 -> 학습 데이터는 다 맞히지만 noise까지 외움.

새 데이터에서 성능 저하(일반화 실패).

해결: max_depth 등으로 깊이 제한.

40. 정답: 루트에서 links <= 5? 8 <= 5는 거짓이므로 False(오른쪽)로 간다. 다음 노드 caps <= 40? 70 <= 40은 거짓이므로 False(오른쪽)로 간다. 도달한 잎은 Ham 0, Spam 5이므로 더 많은 쪽인 Spam으로 분류된다.

채점 포인트

links <= 5? 8은 거짓 -> 오른쪽(False).

caps <= 40? 70은 거짓 -> 오른쪽(False).

도달한 잎 Ham 0, Spam 5 -> Spam으로 분류.

42. 정답: 의사결정트리는 한 노드에 여러 클래스가 섞인 정도(불순도)가 가장 많이 줄어드는(가장 순수하게 갈라지는) 특성과 기준값을 골라 나눈다. 이 그림에서는 color 기준으로 나누자 한쪽은 No만, 다른 쪽은 Yes만 남아 양쪽이 완전히 순수해졌으므로, color가 데이터를 가장 잘 갈라주는 좋은 분할 기준이다.

채점 포인트

섞인 정도(불순도)가 가장 많이 줄어드는 기준으로 분할.

color 분할 후 양쪽이 한 클래스만 남아 순수해짐.

순수하게 갈라줄수록 좋은 분할.

43. 정답: 루트(맨 위)에서 나누는 특성은 데이터를 클래스 별로 가장 잘 갈라주는(불순도를 가장 크게 줄이는) 특성이다. `study_hours <= 4`로 나누자 한쪽이 거의 Fail로 몰려 분류가 크게 좋아지므로, 이 트리에서 `study_hours`가 가장 중요한 특성이라고 볼 수 있다.

채점 포인트

루트 특성 = 데이터를 가장 잘 갈라주는(불순도 최대 감소) 특성.

`study_hours`로 나누자 한쪽이 거의 Fail -> 분류가 크게 개선.

따라서 `study_hours`가 가장 중요한 특성.

45. 정답: 모델은 학습한 범위($x=1\sim10$) 안에서의 관계만 확인한 것이다. $x=20$ 은 한 번도 학습하지 않은 범위 밖(외삽)이라, 그 구간에서도 똑같은 직선 관계가 이어진다는 보장이 없다. 실제로는 관계가 달라질 수 있어 예측이 크게 빗나갈 수 있다.

채점 포인트

$x=20$ 은 학습 범위($1\sim10$) 밖 -> 외삽.

범위 밖에서도 같은 직선 관계가 유지된다는 보장 없음.

예측 신뢰도 낮음.

44. 정답: 데이터가 직선이 아니라 곡선(비선형) 모양으로 분포해 있어서, 어떤 직선을 그어도 점들의 경향을 따라갈 수 없다. 선형회귀는 직선만 그릴 수 있어 곡선 관계를 표현하지 못하므로 R^2 가 낮다. 이런 경우 곡선을 표현할 수 있는 모델이 필요하다.

채점 포인트

데이터가 비선형(곡선) 관계.

직선 모델은 곡선을 못 따라감 -> R^2 낮음.

(분산이 아니라 '비선형'이 핵심 원인)

46. 정답: graph A의 R^2 가 더 높다. A는 점들이 직선에 바짝 붙어 있어(흩어짐이 작아) 직선이 데이터를 잘 설명하므로 R^2 가 1에 가깝다. B는 점들이 직선에서 넓게 흩어져 있어 직선의 설명력이 떨어져 R^2 가 낮다.

채점 포인트

R^2 는 1에 가까울수록 점들이 직선에 잘 맞춤.

A: 직선에 바짝 붙음(분산 작음) -> R^2 높음.

B: 넓게 흩어짐 -> R^2 낮음.

47. 정답: 선형회귀는 각 점과 직선 사이의 세로 거리(잔차)들을 제공해서 모두 더한 값이 가장 작아지도록 직선의 기울기와 절편을 정한다. 즉 전체 오차(잔차)가 최소가 되는 직선을 찾는 것이다.

채점 포인트

잔차 = 점과 직선 사이의 세로 거리(오차).

잔차를 제공해 더한 값(전체 오차)이 최소가 되도록 직선 결정.

49. 정답: 정상 메일(Ham) 50개 중 15개를 스팸으로 잘못 분류했다(위양성). 스팸 필터에서 위양성은 중요한 정상 메일이 스팸함으로 가서 사용자가 놓치게 되는 문제라 특히 곤란하다. 스팸을 일부 못 거르는 것(위음성, 3개)보다, 정상 메일을 스팸으로 버리는 위양성을 줄이는 것이 더 중요하다.

채점 포인트

정상 메일 50개 중 15개를 스팸으로 오분류(위양성).

위양성 -> 중요한 정상 메일을 놓침(가장 곤란).

스팸 필터에서는 위양성을 줄이는 것이 중요.

48. 정답: graph A는 직선 기울기가 양수라 x가 커질수록 y도 커지는 양의 상관(비례) 관계다. graph B는 기울기가 음수라 x가 커질수록 y는 작아지는 음의 상관(반비례) 관계다.

채점 포인트

A: 기울기 양수 -> x 증가 시 y 증가(양의 상관).

B: 기울기 음수 -> x 증가 시 y 감소(음의 상관).

50. 정답: 정확도 = $(985+2)/1000$ = 약 98.7%로 높아 보인다. 하지만 실제 양성 10개 중 2개만 맞히고 8개를 놓쳤다. 데이터가 정상 쪽으로 크게 치우쳐 있어 모두 정상이라고만 찍어도 정확도가 높게 나오므로, 정작 찾아야 할 양성을 잘 찾는지는 정확도만으로 알 수 없다.

채점 포인트

정확도 = $(985+2)/1000$ = 약 98.7%.

그러나 양성 10개 중 2개만 맞힘(8개 놓침).

불균형 데이터에서는 정확도가 높아도 소수 클래스를 못 찾을 수 있음.

51. 정답: 정확도 = 맞게 분류한 수 / 전체 수. 맞게 분류한 것은 대각선의 50(실제 Neg를 Neg로) + 40(실제 Pos를 Pos로) = 90이고, 전체는 50+10+20+40 = 120이다. 따라서 정확도 = $90/120 = 0.75 = 75\%$ 이다.

채점 포인트

맞게 분류 = 대각선 합 = $50 + 40 = 90$.

전체 = $50+10+20+40 = 120$.

정확도 = $90/120 = 75\%$.

52. 정답: Model X가 더 적합하다. 환자를 놓치면 안 되는 상황에서 치명적인 오류는 실제 양성을 음성으로 판정하는 위음성이다. 위음성은 Model X가 2명, Model Y가 18명으로, X가 환자를 훨씬 적게 놓친다. X는 대신 정상인을 양성으로 판정하는 위양성이 많지만(30명), 이 상황에서는 환자를 놓치지 않는 것이 우선이므로 X가 낫다.

채점 포인트

환자 놓침 = 위음성(실제 Pos를 Neg로). $X=2, Y=18$.

X가 위음성이 훨씬 적어 환자를 덜 놓침.

환자를 놓치면 안 되는 상황 -> Model X가 적합.

